


1. “Работа с Big Data”


Создание Yandex Data Proc в Yandex Cloud и обработка данных

Создаем кластер Yandex Data Proc в яндекс клауде



Обработка данных

В демонстрации я не нашел примера данных для задания, поэтому создал свои и загрузил на Yandex Object Storage.



Ниже код ruyspark в ноутбуке Zeppelin с демонстрацией чтения и записи в S3

ui-c9q1pq43mrbg5av4vlk-rc1d-dataproc-m-4olbf3ug0u4ciu42-8890.dataproc-ui.yandexcloud.nethw-etl - Zeppelin

LoopЯндексGmailycEЛКMS HSEAirflowDAGs - AirflowDQ checksdpVaultIntegrations moniSourcescontest.yandex.ru

ZeppelinNotebookJob

hw-etl

```
%pyspark
import pyspark.sql.functions as F

df = spark.read.option("multiline", "true").json('s3a://hse-1/raw/example.json', multiline=True)

explode_catalogs = df.select(F.explode('catalogs'))
catalogs = explode_catalogs.select('col.*')
catalogs.show()
catalogs.write.mode("overwrite").parquet('s3a://hse-1/data/catalogs.parquet')

explode_offers = df.select(F.explode('offers'))
offers = explode_offers.select('col.*')
offers.show()
offers.write.mode("overwrite").parquet('s3a://hse-1/data/offers.parquet')
```

catalog_id	is_active	slug	sort_order	title
cat-electronics	true	electronics	1	Electronics
cat-books	true	books	2	Books
cat-home	false	home	3	Home

catalog_id	currency	in_stock	name	offer_id	price	tags
cat-electronics	USD	true	USB-C cable 2m	off-1001	12.5	[cable, usb-c]
cat-electronics	USD	false	Mechanical keyboard	off-1002	129.0	[keyboard, mechan...
cat-books	USD	true	Learning Spark	off-2001	54.9	[spark, data]
cat-home	USD	true	Desk Lamp LED	off-3001	34.0	[lamp, led]

Took 4 sec. Last updated by anonymous at May 03 2026, 12:57:38 PM.

Результат на S3:

Object Storage / Бакеты / hse-1 / data

Объекты

Поиск по началу имени объекта, включая префикс

☐	Имя	Размер	Класс хранилища	Последнее изменение	Метки	
☐	catalogs.parquet	—	—	—	—	...
☐	offers.parquet	—	—	—	—	...

2. «NoSQL в ETL-процессах» Создание кластера Kafka, Store Doc и настройка трансфера

Создаем кластер Kafka

The screenshot displays the 'Managed Service for Kafka' console for a cluster named 'kafka-etl'. The interface is in Russian and includes a sidebar with navigation options like 'Обзор' (Overview), 'Топики' (Topics), 'Коннекторы' (Connectors), 'Хосты' (Hosts), 'Пользователи' (Users), 'Мониторинг' (Monitoring), 'Права доступа' (Access Rights), 'Логи' (Logs), 'Операции' (Operations), 'Обслуживание' (Maintenance), and 'Трансферы' (Transfers). The main content area shows the cluster's status as 'Alive' and provides a summary of its configuration and resources.

Обзор

Обратите внимание 1

Обслуживание запланировано на 20.05.2026, в 05:29 (UTC)
Set kafka throttling value to pillar [Перейти к заданию](#)

Провести сейчас Перенести

Имя kafka-etl
Идентификатор c9qvb5or0lpule2lv14p
Дата создания 02.05.2026, в 22:18
Окружение PRODUCTION
Версия 3.9.2 [?](#)
Реестр схем данных ☒ Да
Kafka Rest API ☒ Да
Kafka UI [?](#) [Перейти](#)

Доступность Alive

Все хосты работают нормально, все запущенные операции были успешно выполнены.

Кластер отказоустойчив [?](#) ☒ Нет

Обслуживание

Обслуживание (UTC) среда 05:00 - 06:00 [✎](#)

Ресурсы

КАФКА

Класс хоста s4a-c2-m8 (2 vCPU, 100% vCPU rate, 8 ГБ RAM)
Хранилище 32 ГБ network-ssd [?](#)
Автоматическое увеличение размера хранилища До 32 ГБ [?](#)

Сеть

Облачная сеть dataproc-network
Публичный доступ ☒ Да
Группы безопасности default-sg-enp9g1f6oe0ej1l2hoof, dataproc-sg

Дополнительные настройки

Защита от удаления ☒ Выключена

Документация

- [Как устроен сервис Managed Service for Apache Kafka](#)
- [Начать работу с Managed Service for Apache Kafka](#)
- [Подключиться к топикам в кластере Apache Kafka](#)
- [Топики и разделы](#)
- [Тарифы Managed Service for Apache Kafka](#)
- [История изменений](#)

Далее создаем топик sensors

kafbat UI

dfa5a7e

12.11.2025, 14:21:33

Dashboard

- kafka-etl
- Brokers
- Topics
- Consumers
- Schema Registry
- ACL

kafka-etl

Topics

Search by Topic Name

Delete selected topics

Copy selected topic

Purge messages of selected topics

☒	Topic Name
☐	IN __consumer_offsets
☐	IN __schema_registry
☒	sensors

Создаем кластер Yandex StoreDoc

Настраиваем Yandex DataTransfer между ними

eti-hw-transfer

Обзор

Логг

Операции

Мониторинг

Документация

Как устроен сервис Data Transfer

Начать работу с Data Transfer

Подготовиться к трансферу

Управление эндпоинтом

Тарифы Data Transfer

История изменений

Обзор

История статусов

Общая информация

Эндпоинты

Настройки подключения

12:14

12:19

12:24

12:29

12:34

12:39

12:44

12:49

11:00

11:05

11:10

11:15

11:20

11:25

11:30

11:35

11:40

11:45

11:50

11:55

12:00

12:05

12:10

12:15

12:20

12:25

12:30

12:35

12:40

12:45

12:50

12:55

13:00

Ok

Общая информация

Автор: Павел Брагин
pobragin@edu.hse.ru

Идентификатор: dttt49vq145198071n15

Дата создания: 03.05.2026, в 11:53

Имя: eti-hw-transfer

Статус: Реплицируется

Метки: —

Эндпоинты

Источник

Kafka • kafka-eti • dtesjcr6hu24a21b1p6q

Автор: Павел Брагин
pobragin@edu.hse.ru

Идентификатор: dtesjcr6hu24a21b1p6q

Дата создания: 03.05.2026, в 11:52

Имя: kafka-eti

Статус: Создан

Метки: —

Тип: Источник

База данных: Kafka

Параметры эндпоинта

Для корректной работы трансфера из Apache Kafka® выполните следующие рекомендации:

1. У пользователя должна быть роль ACCESS_ROLE_CONSUMER на топике-источнике.

2. Проверьте настройки внешнего приёмника Apache Kafka® по инструкции.

Эндпоинты



Источник

Kafka • kafka-etl • dtesjcr6hu24a2lbp6q



Автор..... Павел Брагин
pobragin@edu.hse.ru

Идентификатор..... dtesjcr6hu24a2lbp6q

Дата создания..... 03.05.2026, в 11:52

Имя..... kafka-etl

Статус..... Создан

Метки..... —

Тип..... Источник

База данных..... Kafka

Параметры эндпоинта



Для корректной работы трансфера из Apache Kafka® выполните следующие рекомендации:



1. У пользователя должна быть роль `ACCESS_ROLE_CONSUMER` на топике-источнике.

2. Проверьте настройки внешнего приёмника Apache Kafka® по инструкции.

Настройки подключения

Тип подключения..... Ручная настройка

Тип инсталляции..... Кластер Managed Service for Apache Kafka

Кластер Managed Service for Apache Kafka

Кластер Managed Service for Apache Kafka..... c9qvb5or0lpule2lv14p

Аутентификация..... SASL

Имя пользователя..... mkf-user

Полное имя топика >

Группы безопасности >

Расширенные настройки >



Приёмник

MongoDB/Yandex StoreDoc • storedoc-etl • dte16gd80joap265peie



Автор Павел Брагин
pobragin@edu.hse.ru

Идентификатор dte16gd80joap265peie

Дата создания 03.05.2026, в 11:53

Имя storedoc-etl

Статус Создан

Метки —

Тип Приёмник

База данных MongoDB/Yandex StoreDoc

Параметры эндпоинта



Для корректной работы трансфера в MongoDB/Yandex StoreDoc выполните следующие рекомендации:

1. Убедитесь, что у [пользователя](#) есть разрешение `readWrite` на созданную базу.
2. Чтобы шардировать переносимые коллекции в кластере-приёмнике Yandex StoreDoc, выполните требования, описанные в [инструкции](#).
3. Проверьте настройки внешнего приёмника **MongoDB/Yandex StoreDoc** по [инструкции](#).

Настройки подключения

Тип подключения Ручная настройка

Тип установки Кластер Yandex StoreDoc

Кластер Yandex StoreDoc

Кластер Yandex StoreDoc c9q2vtvicfps0tkgj53

Источник аутентификации db1

Пользователь mmg-user

Группы безопасности >

База данных db1

Политика очистки Не очищать

Параметры трансфера



Тип трансфера Репликация

Настройки репликации

Отправляем данные в топик Кафки через jq и kcat

```
{ } sample.json 1, U x
hw-practice > data > { } sample.json > ...
1  {
2    "device_id": "iv9a94th6rzt*****",
3    "datetime": "2020-06-05 17:27:00",
4    "latitude": 55.70329032,
5    "longitude": 37.65472196,
6    "altitude": 427.5,
7    "speed": 0,
8    "battery_voltage": 23.5,
9    "cabin_temperature": 17,
10   "fuel_level": null
11 }
12 {
13   "device_id": "rhbbh3y08qm*****",
14   "datetime": "2020-06-06 09:49:54",
15   "latitude": 55.71294467,
16   "longitude": 37.66542005,
17   "altitude": 429.13,
18   "speed": 55.5,
19   "battery_voltage": null,
20   "cabin_temperature": 18,
21   "fuel_level": 32
22 }
23 {
24   "device_id": "iv9a94th6rzt*****",
25   "datetime": "2020-06-07 15:00:10",
26   "latitude": 55.70985913,
27   "longitude": 37.62141918,
28   "altitude": 417.0,
29   "speed": 15.7,
30   "battery_voltage": 10.3,
31   "cabin_temperature": 17,
32   "fuel_level": null
33 }
```

Problems 1 Output Debug Console Terminal Ports

- pavelbragin@RM-LT-64V27D etl-processes % cd hw-practice/data
- pavelbragin@RM-LT-64V27D data % jq -rc . sample.json | kcat -P \
-b rc1d-ju4n14mrrdhe1b84.mdb.yandexcloud.net:9091 \
-t sensors \
-k key \
-X security.protocol=SASL_SSL \
-X sasl.mechanism=SCRAM-SHA-512 \
-X sasl.username="mkf-user" \
-X sasl.password="mkf-user" \
-X "ssl.ca.location=\$HOME/.kafka/certs/YandexInternalRootCA.crt" -Z
- pavelbragin@RM-LT-64V27D data %

Проверяем результат в StoreDoc – данные появились, трансфер сработал.

The screenshot shows the Yandex Cloud StoreDoc interface. On the left, a sidebar lists connections to Yandex Cloud services, including ClickHouse and MongoDB. The main panel displays a MongoDB query: `db.sensors.find().limit(100)`. Below the query, a 'Выполнить' (Execute) button is visible. The 'Результат' (Result) section shows the output of the query, which is a JSON array of sensor data records. The first record is expanded, showing fields such as `_id`, `device_id`, `datetime`, `latitude`, `longitude`, `altitude`, `speed`, `battery_voltage`, `cabin_temperature`, `fuel_level`, `timestamp`, `partition`, `offset`, and `id`.

```
{
  "_id": "iv9a94th6rzt*****-2026\\-05\\-03 12:03:27.982 +0300 MSK-{"partition":0,"topic":"sensors"}-0-1",
  "device_id": "iv9a94th6rzt*****",
  "datetime": "2020-06-05 17:27:00",
  "latitude": 55.78329802,
  "longitude": 37.65472196,
  "altitude": 427.5,
  "speed": 0,
  "battery_voltage": 23.5,
  "cabin_temperature": 17,
  "fuel_level": null,
  "timestamp": Date("2026-05-03T09:03:27.982Z"),
  "partition": "0",
  "topic": "sensors",
  "offset": NumberDecimal("0"),
  "id": 1
}
```